

Modelos Substitutos Baseados em Redes Neurais Profundas para Predição de Campos de Escoamento em Cabines Veiculares

[Nome do autor]

Universidade Federal de Santa Catarina — Centro Tecnológico de Joinville

Orientador: *[Nome do orientador]*

28 de abril de 2026

Sumário

1	Metodologia	2
1.1	Base de Dados CFD	2
1.2	Variáveis de Entrada e Saída	2
1.3	Divisão por Regiões da Cabine	2
1.4	Arquitetura da Rede Neural	3
1.4.1	Seleção de Arquitetura	3
1.5	Estratégia de Treinamento	4
1.6	Validação Cruzada K-Fold	4
1.7	Métricas de Avaliação	4
2	Resultados	5
2.1	Estabilidade da Validação Cruzada por Região	5
2.2	Análise por Variável — Melhor Dobra	6
2.3	Distribuição Cumulativa dos Erros Absolutos	7
2.4	Comparação Visual: CFD Real versus Rede Neural	7
2.4.1	Campos de Pressão	7
2.4.2	Campo de Temperatura	7
2.4.3	Região <i>mt_r_foot</i> — Pé Direito do Motorista	7

1 Metodologia

1.1 Base de Dados CFD

Os dados de treinamento foram gerados por meio de simulações de Dinâmica dos Fluidos Computacional (CFD) em regime permanente de uma cabine veicular reconstruída a partir da geometria de referência de [1]. O solver ANSYS Fluent foi utilizado com o modelo de turbulência RANS $k-\omega$ SST e o método das ordenadas discretas (DOM) para modelagem da transferência de calor por radiação.

Para cobrir o espaço operacional do sistema HVAC, foram definidos três fatores de projeto: velocidade de insuflamento (Vel), temperatura de insuflamento (T_{insu}) e vazão volumétrica (Q_{insu}). Um total de **45 casos de simulação** foi gerado por meio de um Planejamento de Experimentos (DOE) com amostragem por Hipercubo Latino (LHS), garantindo cobertura uniforme do espaço de parâmetros.

1.2 Variáveis de Entrada e Saída

Cada ponto da malha CFD é descrito por seis variáveis de entrada e nove variáveis alvo, conforme a Tabela 1.

Tabela 1: Variáveis de entrada e saída da rede neural.

Papel	Variável	Descrição	Unidade
Entrada	x	Coordenada espacial X	m
	y	Coordenada espacial Y	m
	z	Coordenada espacial Z	m
	Vel	Velocidade de insuflamento	m s^{-1}
	T_{insu}	Temperatura de insuflamento	K
	Q_{insu}	Vazão volumétrica de entrada	$\text{m}^3 \text{s}^{-1}$
Saída	p	Pressão manométrica	Pa
	u	Velocidade em X	m s^{-1}
	v	Velocidade em Y	m s^{-1}
	w	Velocidade em Z	m s^{-1}
	T	Temperatura do ar	K
	G	Radiação incidente	W m^{-2}
	T_r	Temperatura radiante	K
	q_r	Fluxo de calor radiativo	W m^{-2}
	v_r	Velocidade resultante	m s^{-1}

1.3 Divisão por Regiões da Cabine

O domínio volumétrico da cabine foi segmentado em oito regiões de análise, alinhadas às zonas corporais relevantes para o cálculo de índices de conforto térmico (PMV/PPD, Temperatura Radiante Média):

- **fp_head**: região da cabeça do passageiro dianteiro;
- **lrp_head**: região da cabeça do passageiro traseiro esquerdo;

- **rrp_head**: região da cabeça do passageiro traseiro direito;
- **mt_head**: região da cabeça do motorista;
- **mt_core**: região do tronco do motorista;
- **mt_l_foot**: região do pé esquerdo do motorista;
- **mt_r_foot**: região do pé direito do motorista;
- **outlet**: região de saída de ar.

Para cada região treina-se uma rede neural independente, pois os campos de velocidade, temperatura e radiação diferem substancialmente entre zonas (e.g., região dos pés versus cabeça do motorista).

1.4 Arquitetura da Rede Neural

Adotou-se uma arquitetura de Perceptron Multicamadas (MLP) totalmente conectado, implementada em TensorFlow/Keras. A estrutura é:

$$\hat{\mathbf{y}} = f_L \circ \dots \circ f_1(\text{Norm}(\mathbf{x})) \quad (1)$$

onde $\text{Norm}(\cdot)$ é uma camada de normalização adaptativa ajustada sobre os dados de treinamento, cada f_i é uma camada densa com ativação ReLU, e a camada de saída f_L utiliza ativação linear. A notação $N \times M$ denota M camadas ocultas com N neurônios cada.

1.4.1 Seleção de Arquitetura

A busca pela melhor arquitetura foi conduzida na região *fp_head*, avaliando quatro configurações quanto à perda de validação em 30 dobras de validação cruzada. A Tabela 2 apresenta os resultados.

Tabela 2: Comparação de arquiteturas na região *fp_head* (30 dobras de K-Fold, MSE de validação).

Arquitetura	Parâmetros	MSE médio	Desv. pad.	MSE mínimo
128×5	68.105	1,3315	0,3172	0,7491
256×5	267.273	0,4700	0,0707	0,3349
512×5	1.058.825	0,4391	0,0794	0,3540
512×4	796.169	0,4023	0,0510	0,2981

A arquitetura 512×4 alcançou tanto o menor MSE médio quanto o menor desvio padrão entre dobras, indicando melhor generalização e maior estabilidade. Além disso, possui 25% menos parâmetros do que a 512×5 , tornando-a mais eficiente computacionalmente. Por esses motivos, a configuração 512×4 foi adotada para o treinamento de todas as regiões.

Efeito da regularização L2. Experimentos com penalização L2 na região *fp_head* demonstraram efeito prejudicial ao desempenho: $\lambda = 10^{-4}$ elevou o MSE médio para 1,1542 e $\lambda = 10^{-5}$ para 0,5700, ambos superiores ao modelo sem regularização (0,4023). Conclui-se que o K-Fold de 30 dobras fornece estimativa robusta de generalização, tornando a regularização L2 desnecessária neste contexto.

1.5 Estratégia de Treinamento

O otimizador Adam foi utilizado com taxa de aprendizado inicial $\eta_0 = 10^{-3}$, $\beta_1 = 0,9$ e $\beta_2 = 0,999$. Dois mecanismos de controle foram empregados:

- **ReduceLROnPlateau:** reduz η por fator 0,9 após 50 épocas sem melhora na perda de validação (cooldown de 20 épocas, $\eta_{\min} = 10^{-5}$);
- **EarlyStopping:** interrompe o treinamento após 200 épocas sem melhora na perda de validação, restaurando os pesos da melhor época.

A função de perda é o Erro Quadrático Médio (MSE) calculado simultaneamente sobre as 9 variáveis alvo. O tamanho de *batch* foi fixado em 500 pontos e o número máximo de épocas em 5000.

1.6 Validação Cruzada K-Fold

Para cada região, aplica-se validação cruzada com $k = 30$ dobras (*KFold* do scikit-learn, `random_state=42`, embaralhamento ativado). Cada dobra divide o conjunto de pontos CFD em $\approx \frac{29}{30}$ para treinamento e $\frac{1}{30}$ para validação. A dobra com menor perda de validação é registrada como modelo representativo da região.

1.7 Métricas de Avaliação

O desempenho é avaliado no conjunto de validação pelas seguintes métricas, calculadas separadamente para cada variável alvo j :

$$\text{MSE}_j = \frac{1}{N} \sum_{i=1}^N (\hat{y}_{ij} - y_{ij})^2 \quad (2)$$

$$\text{MAE}_j = \frac{1}{N} \sum_{i=1}^N |\hat{y}_{ij} - y_{ij}| \quad (3)$$

$$R_j^2 = 1 - \frac{\sum_i (\hat{y}_{ij} - y_{ij})^2}{\sum_i (y_{ij} - \bar{y}_j)^2} \quad (4)$$

onde N é o número de pontos no conjunto de validação, $\hat{y}_{ij}$ é a predição da rede e y_{ij} o valor CFD de referência.

2 Resultados

2.1 Estabilidade da Validação Cruzada por Região

A Tabela 3 apresenta as estatísticas dos 30 folds de K-Fold para cada região treinada com a arquitetura 512×4 .


Tabela 3: Estatísticas do MSE de validação nos 30 folds de K-Fold por região (arquitetura 512×4 , sem regularização L2).

Região	Descrição	n	Médio	Desv. pad.	Mínimo	Máximo
<i>mt_head</i>	Cabeça do motorista	30	0,2674	0,0471	0,1973	0,4162
<i>fp_head</i>	Cabeça passageiro diant.	30	0,4023	0,0510	0,2981	0,5125
<i>mt_core</i>	Tronco do motorista	23	0,4471	0,0644	0,3539	0,5929
<i>lrp_head</i>	Cabeça passageiro tras. esq.	30	0,4538	0,0624	0,3544	0,6222
<i>rrp_head</i>	Cabeça passageiro tras. dir.	—	—	—	—	—
<i>mt_l_foot</i>	Pé esquerdo do motorista	—	—	—	—	—
<i>mt_r_foot</i>	Pé direito do motorista	30	0,1641	0,0181	0,1345	0,2111
<i>rrp_head</i>	Cabeça passageiro tras. dir.	—	—	—	—	—
<i>mt_l_foot</i>	Pé esquerdo do motorista	—	—	—	—	—
<i>outlet</i>	Região de saída de ar	—	—	—	—	—


n = dobras concluídas. *mt_core* com treinamento em andamento.

A região *mt_r_foot* apresenta o menor MSE médio entre todas as regiões avaliadas ($\bar{L} = 0,1641$, $\sigma = 0,0181$), com notável estabilidade entre dobras. A região *mt_head* ocupa o segundo melhor desempenho ($\bar{L} = 0,2674$). As regiões *mt_core* e *lrp_head* exibem maior dispersão, possivelmente reflexo de gradientes mais complexos nessas zonas do domínio.

A Figura 1 ilustra a distribuição dos valores de MSE de validação por meio de boxplots e da evolução por dobra, evidenciando a robustez do processo de treinamento.



(a) Boxplot dos 30 folds por região.



(b) Val. MSE por dobra (marcador = melhor fold).

Figura 1: Distribuição e evolução do MSE de validação nos K-Fold por região (arquitetura 512×4).

2.2 Análise por Variável — Melhor Dobra

Para o modelo representativo de cada região (melhor dobra), calculam-se R^2 e MAE individuais por variável alvo. As Figuras 2 e 3 apresentam esses resultados em formato de mapa de calor.




Figura 2: Coeficiente de determinação R^2 da melhor dobra por região e variável de saída. Valores próximos de 1 (verde) indicam excelente predição; valores baixos (vermelho) indicam maior dificuldade do modelo. Regiões não treinadas serão adicionadas.




Figura 3: Erro Absoluto Médio (MAE) da melhor dobra por região e variável de saída.

A Tabela 4 sintetiza os valores de R^2 obtidos para as quatro regiões treinadas.

Os resultados revelam um padrão consistente entre regiões: as variáveis de pressão (p), temperatura (T), radiação incidente (G), temperatura radiante (T_r) e fluxo radiativo (q_r) apresentam $R^2 > 0,99$ em todas as regiões avaliadas, demonstrando predição praticamente perfeita. As componentes de velocidade (u , v , w , v_r) exibem R^2 entre 0,83 e 0,97, ainda satisfatórios considerando a natureza turbulenta e tridimensional do escoamento.

Tabela 4: Coeficiente de determinação R^2 da melhor dobra por região e variável (512×4 , sem L2). Regiões pendentes indicadas com “-”.

Região	p	u	v	w	T	G	T_r	q_r	v_r
mt_head	0,997	0,875	0,963	0,970	0,997	1,000	0,999	0,999	0,968
fp_head	0,996	0,901	0,958	0,962	0,996	1,000	0,998	0,999	0,965
lrp_head	0,999	0,833	0,899	0,903	0,995	1,000	0,999	0,998	0,856
mt_core	0,999	0,850	0,870	0,885	0,995	1,000	0,999	0,996	0,862
rrp_head	-	-	-	-	-	-	-	-	-
mt_l_foot	-	-	-	-	-	-	-	-	-
mt_r_foot	1,000	0,755	0,720	0,907	0,998	1,000	0,999	0,991	0,823
rrp_head	-	-	-	-	-	-	-	-	-
mt_l_foot	-	-	-	-	-	-	-	-	-
$outlet$	-	-	-	-	-	-	-	-	-

p : pressão; u, v, w : velocidades; T : temperatura; G : rad. incidente; T_r : temp. radiante; q_r : fluxo radiativo; v_r : vel. resultante.

2.3 Distribuição Cumulativa dos Erros Absolutos

A distribuição cumulativa (CDF) dos erros absolutos ponto a ponto, agregada sobre todos os 30 folds, permite avaliar o comportamento estatístico do erro para toda a população de pontos CFD. A Figura 4 apresenta este resultado para a região fp_head .

2.4 Comparação Visual: CFD Real versus Rede Neural

A qualidade das predições espaciais é avaliada por meio de mapas de calor tridimensionais e gráficos de contorno em seções da cabine, para a região fp_head (melhor dobra: fold 21, $MSE_{val} = 0,2981$).

2.4.1 Campos de Pressão

2.4.2 Campo de Temperatura

2.4.3 Região mt_r_foot — Pé Direito do Motorista

Inserir figuras para as regiões pendentes após conclusão dos treinamentos: rrp_head , mt_l_foot , $outlet$.

Referências

Referências

- [1] MAO, Y.; JI WANG; JUNMING LI. Experimental and numerical study of flow and heat transfer characteristics in a passenger compartment. *International Journal of Thermal Sciences*, 2018.




Figura 4: Distribuição cumulativa dos erros absolutos por variável de saída, agregada sobre os 30 folds de K-Fold — região *fp_head*. As linhas tracejadas indicam os percentis 90% (vermelho) e 95% (verde).

- [2] MEDEIROS, M. B. *Análise de parâmetros de conforto térmico de cabine por meio de simulações CFD e redes neurais profundas*. Dissertação (Mestrado em Engenharia e Ciências Mecânicas) — Universidade Federal de Santa Catarina, Joinville, 2025.
- [3] ASHRAE. *ANSI/ASHRAE Standard 55: Thermal Environmental Conditions for Human Occupancy*. Atlanta: ASHRAE, 2023.





Figura 5: Campo de pressão (p): CFD de referência (esquerda), predição da rede neural (centro) e erro absoluto (direita) — região fp_head , fold 21 ($R^2 = 0,996$).



(a) Contorno de pressão.

(b) Contorno de temperatura.

Figura 6: Contornos 2D interpolados (via *griddata*) na casca superior do domínio — pressão (p) e temperatura (T), região fp_head .




Figura 7: Campo de temperatura (T): CFD de referência (esquerda), predição da rede neural (centro) e erro absoluto (direita) — região fp_head , fold 21 ($R^2 = 0,996$).




Figura 8: Campo de pressão (p): CFD de referência, predição da rede neural e erro absoluto — região mt_r_foot , fold 25 ($R^2 = 1,000$).




Figura 9: Campo de temperatura (T): CFD de referência, predição da rede neural e erro absoluto — região mt_r_foot , fold 25 ($R^2 = 0,998$).




Figura 10: Distribuição cumulativa dos erros absolutos por variável — região *mt_r_foot*, todos os 30 folds.